AIoT · HW2 · Multiple Linear Regression

WHO 平均壽命預測：以 CRISP-DM 進行多元線性迴歸分析

資料集：Kaggle「Life Expectancy (WHO)」(193 國、2000–2015 年、20 個候選特徵)

第二個資料集（互動探索器）：Kaggle「Predict the Flood」(Playground Series S4E5，20 個特徵)

作者：taemiyu　　日期：2026-10-27

> 網頁報告：https://aiot-hw2-multiple-linear-regression.vercel.app/
> 互動探索器：https://aiot-hw2-multiple-linear-regression.vercel.app/app
> GitHub Pages：https://taemiyu.github.io/AIOT-HW2-Multiple_Linear_regression/
> 程式碼：https://github.com/taemiyu/AIOT-HW2-Multiple_Linear_regression

目錄

1. 摘要
2. 資料集
3. Business Understanding 商業理解
4. Data Understanding 資料理解
5. Data Preparation 資料準備
6. Modeling 建模與特徵選擇
7. Evaluation 評估（含預測區間圖）
8. Deployment 部署
9. 結論、限制與未來改進
10. GPT 輔助內容
11. NotebookLM 摘要
12. 參考資料

1. 摘要

本報告以 Kaggle 的 WHO Life Expectancy 資料集（2,938 列、22 欄），依 CRISP-DM 六階段建立多元線性迴歸模型預測各國平均壽命。資料準備階段處理了大量缺值與不合理值（刪除 48% 錯誤的 BMI 欄、偏態變數取 log、同國中位數補值），並**依國家切分訓練 / 測試集**，避免同一國家的不同年份洩漏答案。以 Lasso、Forward SFS、RFE、ElasticNet 四種演算法搭配依國家分組的交叉驗證進行特徵選擇，依 1-SD 精簡原則選出 4 個特徵：Income composition of resources、log HIV/AIDS、Adult Mortality、Diphtheria。最終模型在 37 個模型沒看過的國家上達到 **R^2 0.850**、**RMSE 3.75 歲**，95% 預測區間涵蓋 93.4% 的實際值，三項成功標準全部通過。此外，互動探索器加入第二個特徵數大於 13 的 Kaggle 資料集「Predict the Flood」（20 個特徵），全部特徵的 OLS 在測試集達到 R^2 0.842（見 2.2 節）。

2. 資料集

2.1 主資料集：Life Expectancy (WHO)

來源：https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who（Kaggle，作者 KumarRajarshi；原始資料來自 WHO Global Health Observatory 與聯合國）。每列為一個國家在一個年份的資料，預測目標為平均壽命（Life expectancy，歲）。候選特徵共 20 個（不含國家名稱與目標），符合作業「特徵數大於 13」的要求：

特徵	說明	與壽命的相關係數
Year	年份（2000–2015）	+0.170
Status	已開發 / 開發中國家	—
Adult Mortality	成人死亡率：15–60 歲每千人死亡機率	−0.696
infant deaths	每千人嬰兒死亡數	−0.197
Alcohol	15 歲以上人均酒精消費（公升）	+0.405
percentage expenditure	健康支出占人均 GDP 的百分比	+0.382
Hepatitis B	1 歲兒童 B 型肝炎疫苗覆蓋率（%）	+0.257
Measles	每千人麻疹通報病例	−0.158
BMI	國民平均 BMI	+0.568
under-five deaths	每千人五歲以下死亡數	−0.223
Polio	1 歲兒童小兒麻痺疫苗覆蓋率（%）	+0.466
Total expenditure	政府健康支出占政府總支出（%）	+0.218
Diphtheria	1 歲兒童白喉（DTP3）疫苗覆蓋率（%）	+0.479
HIV/AIDS	每千名活產 0–4 歲 HIV/AIDS 死亡數	−0.557
GDP	人均 GDP（美元）	+0.461
Population	人口數	−0.022
thinness 1–19 years	10–19 歲過瘦盛行率（%）	−0.477
thinness 5–9 years	5–9 歲過瘦盛行率（%）	−0.472
Income composition of resources	人類發展指數中的收入組成（0–1）	+0.725
Schooling	平均受教育年數	+0.752

2.2 第二個 Kaggle 資料集：Predict the Flood（互動探索器）

來源：https://www.kaggle.com/competitions/playground-series-s4e5（Kaggle Playground Series Season 4 Episode 5，2024；以 Flood Prediction Factors 資料集為基礎產生的合成資料）。目標為洪水發生機率（FloodProbability，平均 0.505、標準差 0.050），候選特徵 20 個，同樣符合「特徵數大於 13」：

```
MonsoonIntensity、TopographyDrainage、RiverManagement、Deforestation、Urbanization、
ClimateChange、DamsQuality、Siltation、AgriculturalPractices、Encroachments、
IneffectiveDisasterPreparedness、DrainageSystems、CoastalVulnerability、Landslides、
Watersheds、DeterioratingInfrastructure、PopulationScore、WetlandLoss、
InadequatePlanning、PoliticalFactors
```

原始訓練資料有 1,117,957 列，超過瀏覽器端計算的上限，因此以隨機種子 42 抽樣 5,000 列（`datasets/flood.csv`），抽樣後目標的平均與標準差和原始資料一致。資料沒有缺值，各特徵都是 0–16 的整數評分，不需要額外清理。

項目	結果
切分	隨機 80/20（種子 42）：訓練 4,000 列、測試 1,000 列
模型	OLS，全部 20 個特徵
測試集 R^2	0.8421
測試集 RMSE	0.0206
5–fold CV R^2	0.8323 ± 0.011
95% 預測區間涵蓋率	94.6%（平均約 ±0.040）

上表為 Python（statsmodels）重算的結果，與探索器一致（探索器測試集 R^2 0.844、5–fold CV R^2 0.830）。20 個特徵的係數都為正且大小相近（0.0052–0.0059），全部 $p < .001$，因此特徵選擇的 1–SD 原則會保留全部 20 個特徵：少用任何一個因子，誤差都會變大。這和 WHO 資料集「少數特徵就足夠」的結果形成對比。在探索器切換到這個資料集，可以看到特徵選擇比較、係數表，以及含信賴區間與預測區間的預測圖。

3. Business Understanding 商業理解

商業目標：協助衛生政策分析者，從各國的健康、經濟與社會指標估計平均壽命，並找出最關鍵的指標。

商業問題：(1) 哪些指標與平均壽命最相關？ (2) 對「沒看過的國家」能預測多準？ (3) 單一預測的不確定性有多大？

資料探勘目標：建立可解釋的多元線性迴歸模型 `Life expectancy = f(指標)` ，並以未見過的國家評估。

成功標準（建模前訂定）：測試集 $R^2 \geq 0.8$、測試集 RMSE ≤ 4.5 歲、分組 5-fold CV $R^2 \geq 0.75$。

現況評估：資源為一份公開資料集與 Python（scikit-learn、statsmodels）；模型須可解釋；主要風險為缺值多、不合理數值、以及同一國家重複出現造成的資料洩漏。

4. Data Understanding 資料理解

14 個欄位有缺值，1,289 列（44%）至少缺一個值，因此不能直接刪除有缺值的列。與平均壽命相關最強的是受教育年數（r = +0.75）、收入組成指數（+0.72）與成人死亡率（−0.70）。

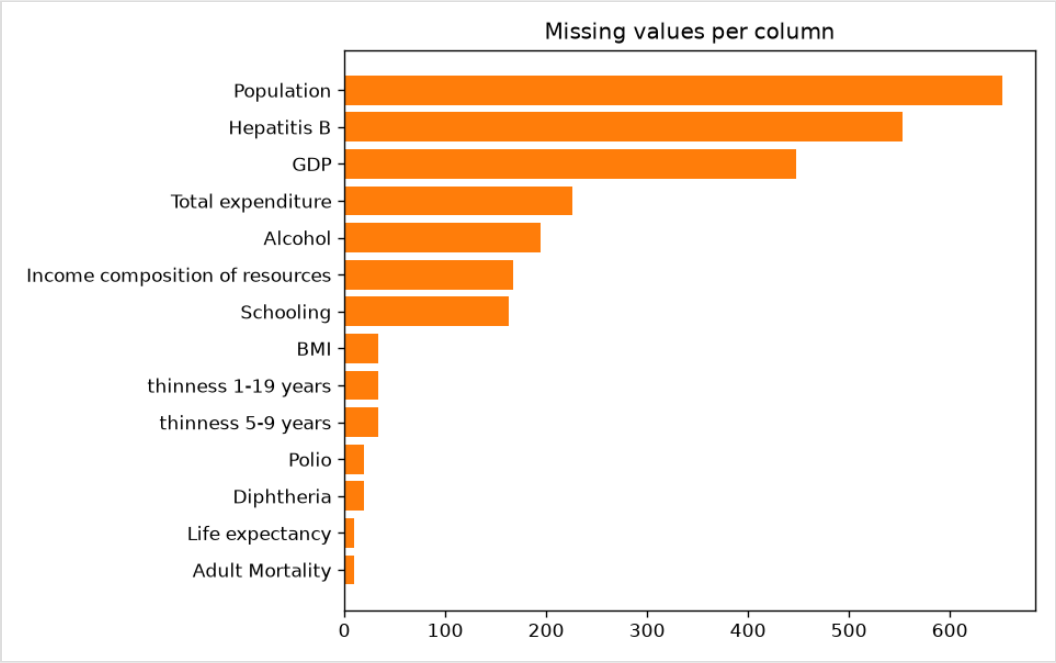


圖 1　各欄缺值數

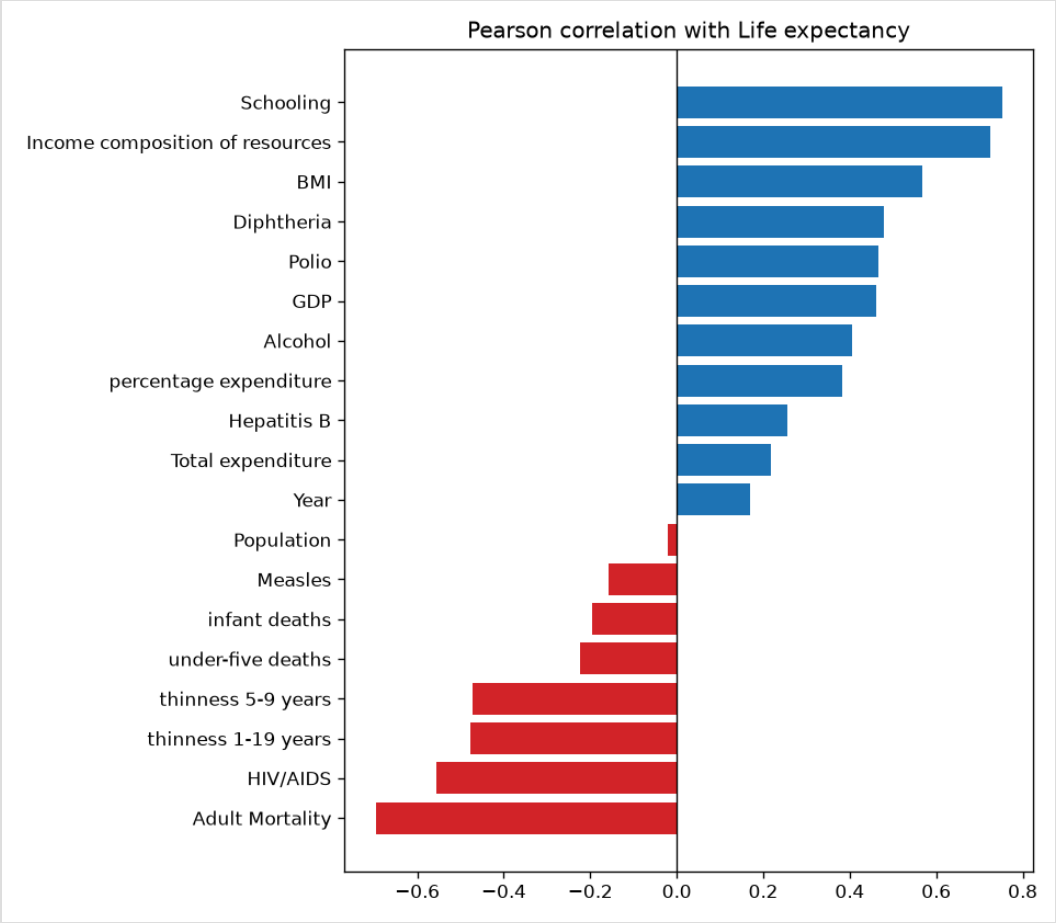


圖 2　各特徵與平均壽命的 Pearson 相關係數

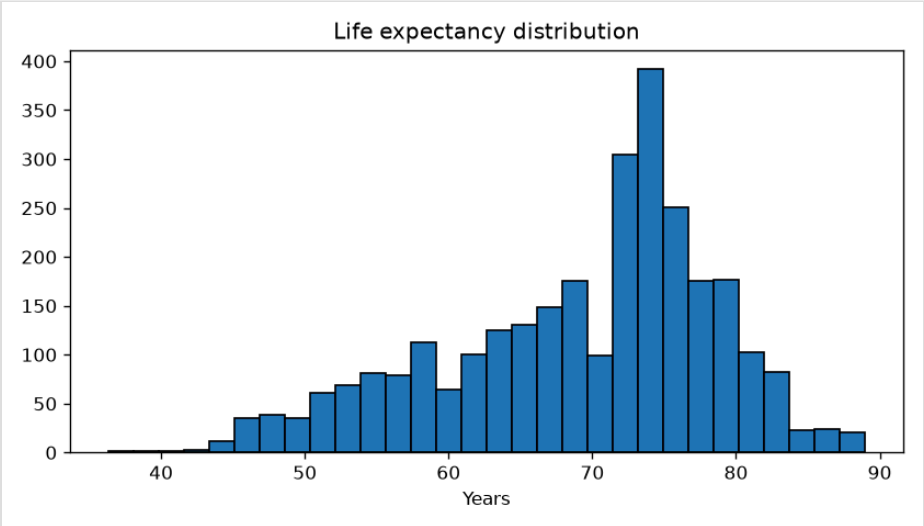


圖 3　平均壽命分布（平均 69.2 歲，範圍 36.3–89.0 歲）

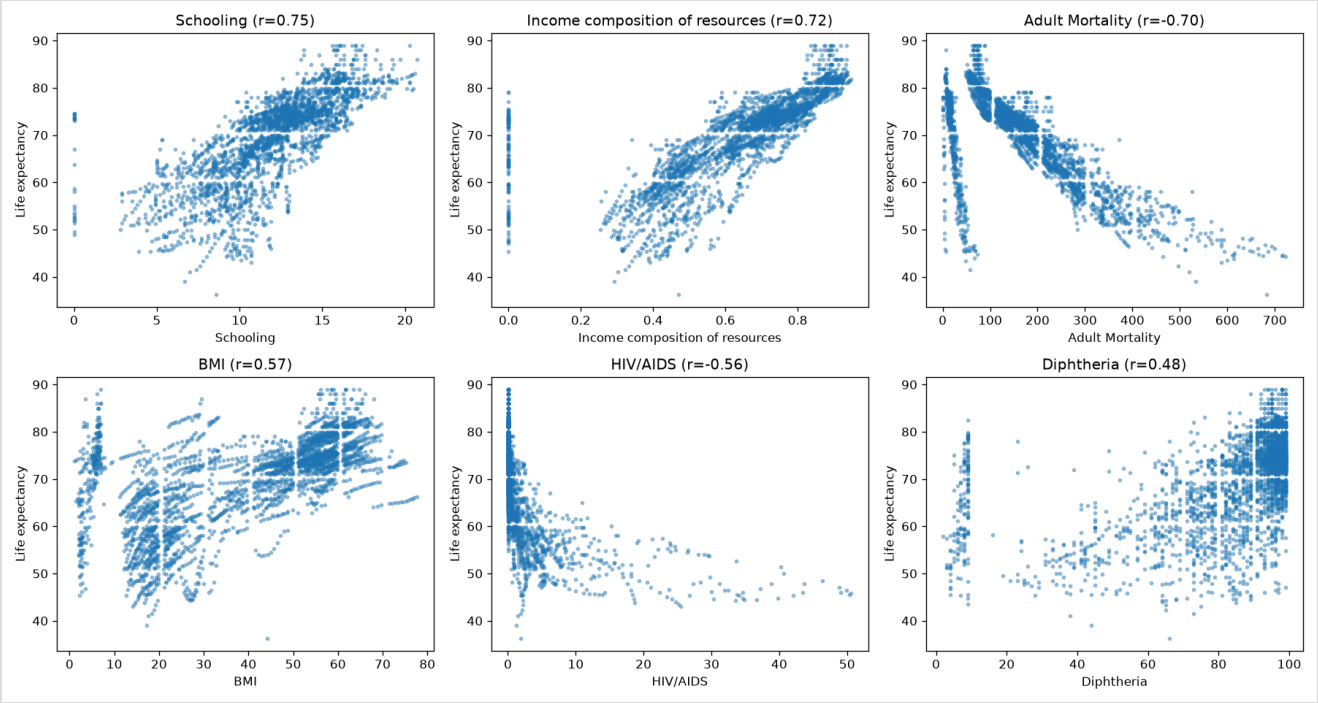


圖 4　相關最強的 6 個特徵與平均壽命的散佈圖

不合理數值與處理

問題	筆數	比例	處理
國家平均 BMI 低於 10 或高於 50	1,422	48.4%	刪除 BMI 欄
教育年數 = 0	28	1.0%	視為缺值後補值
收入組成指數 = 0	130	4.4%	視為缺值後補值
健康支出比例 = 0	611	20.8%	視為缺值後補值
平均壽命（目標）缺值	10	0.3%	刪除該列

5. Data Preparation 資料準備

1. **選擇：**刪除 10 列沒有目標值的資料；刪除 BMI 欄（48% 的值不可能是國家平均）。
2. **清理：**教育年數、收入組成指數、健康支出比例為 0 者視為缺值。
3. **建構：**7 個嚴重偏態的變數取 log(1+x)；Status 轉為 0/1（Status_Developing）。最終候選特徵 19 個。
4. **切分：**以 GroupShuffleSplit **依國家** 80/20 切分（訓練 146 國 2,336 列、測試 37 國 592 列），兩者沒有重疊的國家；交叉驗證同樣使用 GroupKFold。
5. **補值：**共 3,243 格。先用同一國家其他年份的中位數（1,211 格），該國完全沒有資料時才用訓練集中位數（2,032 格）；只使用特徵值、不使用目標值，沒有資料洩漏。開發過程中比較：只用訓練集中位數時測試集 R^2 為 0.813，改用同國中位數後提升至 0.850。

> 為什麼依國家切分：同一國家各年份的資料非常相似，隨機切分會讓模型在測試時「看過」同一國家，使分數被高估。依國家切分的結果更能代表「預測一個新國家」的實際表現。

偏態變數取 log 的效果

變數	偏態（前）	偏態（後）
Population	15.92	−0.55
infant deaths	9.79	0.70
under−five deaths	9.50	0.64
Measles	9.44	0.55
HIV/AIDS	5.40	2.12
percentage expenditure	4.65	0.06
GDP	3.21	−0.14

6. Modeling 建模與特徵選擇

6.1 共線性檢查（VIF）

嬰兒死亡數與五歲以下死亡數幾乎是同一件事，VIF 超過 190；特徵選擇會只留下其中之一。

特徵	VIF
log under-five deaths	203.76（嚴重共線）
log infant deaths	193.64（嚴重共線）
Income composition of resources	10.92（嚴重共線）
log percentage expenditure	7.89
log GDP	7.76
thinness 5–9 years	7.73
thinness 1–19 years	7.64
Schooling	7.41
Diphtheria	2.42
log HIV/AIDS	2.31
Polio	2.23
Alcohol	1.90
Adult Mortality	1.89
log Measles	1.82
Status_Developing	1.79
Hepatitis B	1.61
log Population	1.28
Total expenditure	1.27
Year	1.13

6.2 特徵選擇

四種演算法（Lasso 路徑、Forward SFS、RFE、ElasticNet 路徑）各自只看訓練集，以依國家分組的 5-fold CV RMSE 比較 k = 1 到 19 個特徵。19 個特徵的窮舉搜尋需 524,287 種組合，計算量過大，因此略過。CV RMSE 最低的是 Forward SFS k = 11（3.503 ± 0.188 歲）；依 **1-SD 精簡原則**（CV RMSE 落在最佳值一個標準差內、特徵最少），選出 **Forward SFS，k = 4**。

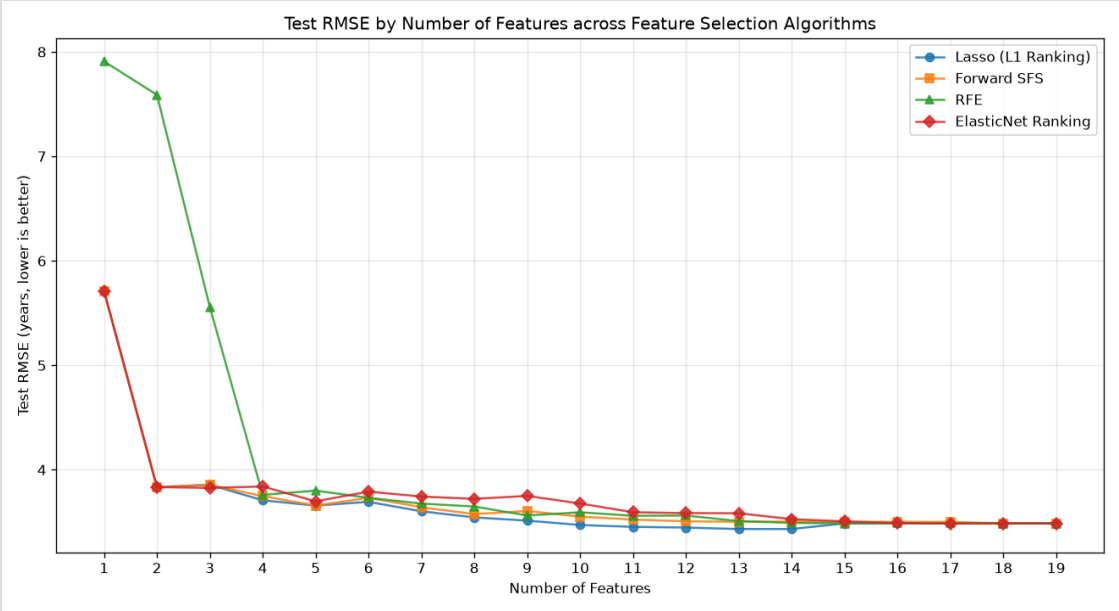


圖 5　各演算法的 Test RMSE 對特徵數

演算法	k（CV 最佳）	k（1-SD）	選出的特徵	CV RMSE	Test RMSE	Test R^2
Lasso (L1 Ranking)	10	4	Income composition of resources, log HIV/AIDS, Adult Mortality, log under-five deaths	3.669	3.708	0.8528
Forward SFS	11	4	Income composition of resources, log HIV/AIDS, Adult Mortality, Diphtheria	3.662	3.748	0.8497
RFE	11	5	log under-five deaths, log infant deaths, Income composition of resources, log HIV/AIDS, Adult Mortality	3.644	3.801	0.8454
ElasticNet Ranking	15	4	Income composition of resources, log HIV/AIDS, Schooling, Adult Mortality	3.759	3.840	0.8421

6.3 模型比較

模型	特徵數	Test R^2	RMSE	MAE	MAPE	分組 CV R^2
OLS (all features)	19	0.8699	3.487	2.675	4.13%	0.8464 ± 0.021
OLS (selected 4)	4	0.8497	3.748	2.815	4.41%	0.8422 ± 0.020
Ridge (all, CV alpha)	19	0.8703	3.482	2.671	4.13%	—
Lasso (all, CV alpha)	19	0.8681	3.510	2.662	4.12%	—

Ridge 與 Lasso 以分組交叉驗證挑選正則化強度，表現與全部特徵的 OLS 相近；精簡模型只用 4 個特徵，誤差只多約 0.26 歲，但更容易解釋。

6.4 最終模型

```
Life expectancy = 49.082 + 32.6493 × Income composition of resources − 3.3603 × log HIV/AIDS − 0.0165 × Adult Mortality + 0.0380 × Diphtheria
```

變數	係數	SE	p	95% CI	叢集穩健 SE	叢集穩健 p	標準化 β
Intercept	49.0816	0.5149	< .001	[48.072, 50.091]	1.6223	< .001	—
Income composition of resources	32.6493	0.6459	< .001	[31.383, 33.916]	2.3721	< .001	0.537
log HIV/AIDS	−3.3603	0.1412	< .001	[−3.637, −3.084]	0.3613	< .001	−0.264
Adult Mortality	−0.0165	0.0008	< .001	[−0.018, −0.015]	0.0030	< .001	−0.216
Diphtheria	0.0380	0.0035	< .001	[0.031, 0.045]	0.0128	.003	0.095

訓練集 n = 2336，R^2 = 0.8551，調整後 R^2 = 0.8548，F = 3,437.76（p < .001）。因同一國家內的誤差相關，推論以依國家分群的叢集穩健標準誤為準；四個係數仍全部顯著。

7. Evaluation 評估

在 37 個沒看過的國家上：R^2 **0.8497**、RMSE **3.75 歲**、MAE 2.82 歲、MAPE 4.41%；只猜平均的基準 RMSE 為 9.95 歲。分組 CV R^2 為 0.842 ± 0.020。

成功標準	結果	判定
測試集 $R^2 \geq 0.8$	0.8497	通過
測試集 RMSE ≤ 4.5 歲	3.75 歲	通過
分組 CV $R^2 \geq 0.75$	0.8422	通過

7.1 預測圖：95% 信賴區間與預測區間

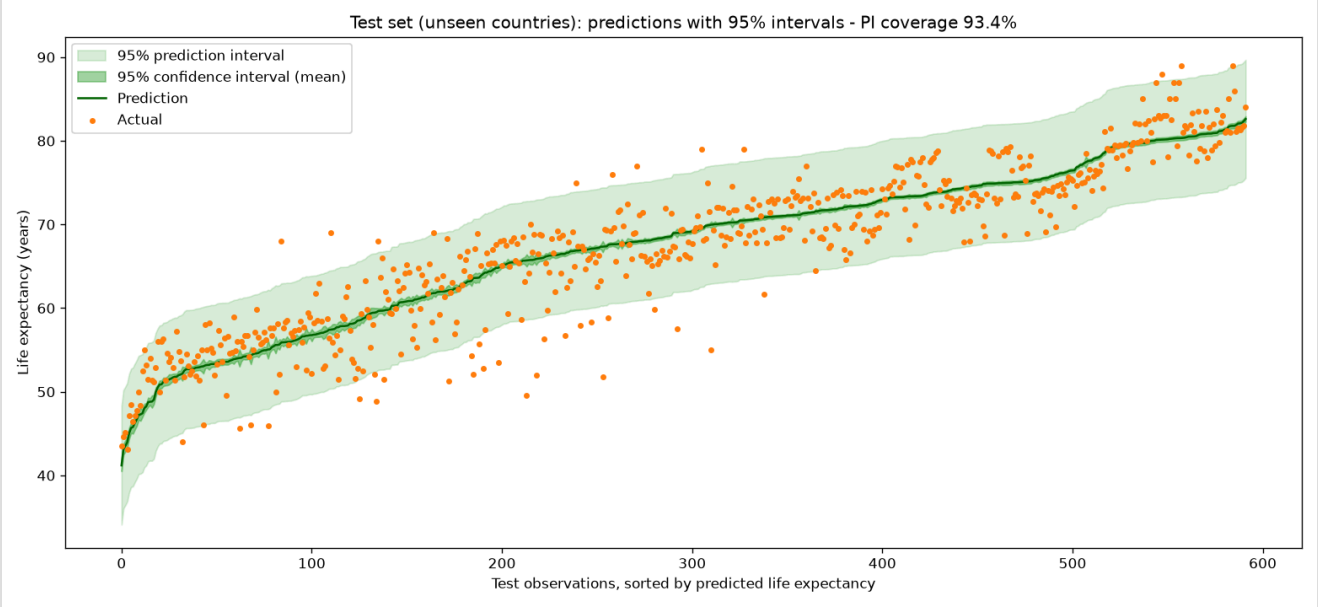


圖 6　測試集預測值（依預測值排序）與 95% 信賴區間（深色，平均約 ±0.32 歲）、95% 預測區間（淺色，平均約 ±7.05 歲）。實際值有 93.4% 落在預測區間內。



圖 7　單純線性迴歸：Life expectancy ~ Income composition of resources（R^2 = 0.726），含 95% 信賴區間與預測區間

7.2 殘差診斷與假設檢定

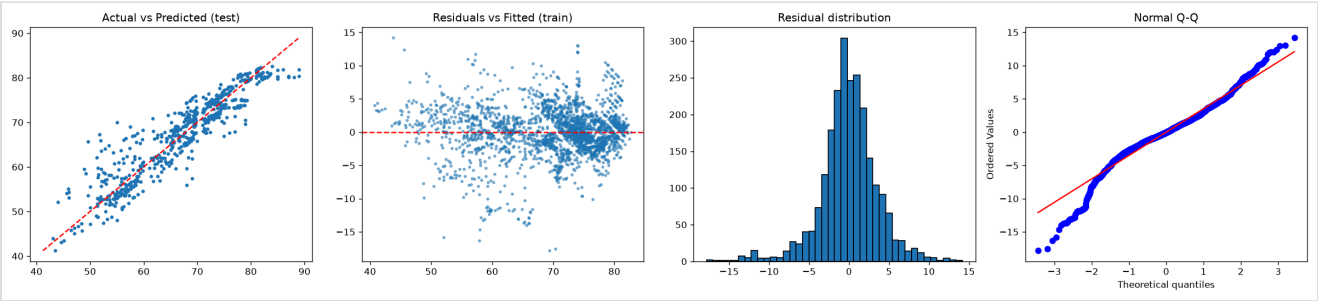


圖 8　實際 vs 預測、殘差 vs 預測值、殘差分布、常態 Q–Q 圖

假設	統計量	p 值	結果
線性（Ramsey RESET）	29.454	< .001	未通過
同質變異（Breusch–Pagan）	119.750	< .001	未通過
殘差常態（Jarque–Bera）	758.008	< .001	未通過
誤差獨立（Durbin–Watson）	0.565	—	未通過
無共線性（最大 VIF）	1.981	—	通過
影響點（Cook's D > 4/n 筆數）	174	—	參考

真實的跨國資料很難完全符合 OLS 假設：殘差有異質變異與非常態，且同一國家內的誤差高度相關（Durbin–Watson 0.56）。因此係數推論改用叢集穩健標準誤，並將非線性項與混合效果模型列為後續改進方向。最終特徵的最大 VIF 為 1.98，沒有共線性問題。

7.3 商業問題的答案

1. **最重要的指標：**Income composition of resources（標準化 β +0.537）、log HIV/AIDS（標準化 β −0.264）、Adult Mortality（標準化 β −0.216）、Diphtheria（標準化 β +0.095）。
2. **預測準確度：**對沒看過的國家，平均誤差約 2.8 歲（RMSE 3.75 歲）。
3. **不確定性：**單一國家年份的 95% 預測區間約 ±7.1 歲；平均值的信賴區間約 ±0.32 歲。

8. Deployment 部署

通過評估後，以全部資料重新擬合最終模型並用 joblib 儲存（`crispdm_output/life_expectancy_model.joblib`）。`predict_life_expectancy()` 接受原始欄位，套用相同的清理、log 轉換與補值，回傳預測值、95% 信賴區間與預測區間。成果另部署為網站（報告與互動探索器）。

國家（2014）	實際	預測	95% 預測區間
Azerbaijan	72.5	74.9	67.8 — 82.0
Belgium	89.0	80.0	73.0 — 87.1
Belize	70.0	72.3	65.2 — 79.4

> Belgium 2014 年的實際值 89.0 歲明顯偏高（比利時實際約 81 歲），是原始資料的錯誤；模型預測約 80 歲反而合理，再次說明資料品質檢查的重要。

監控計畫：新年度資料公布時重新預測並比對；每年重新訓練，或滾動 RMSE 超過 5 歲時立即重訓；輸入超出訓練範圍時警示；定期檢查預測區間涵蓋率是否維持約 95%。

9. 結論、限制與未來改進

- 只用 4 個特徵的線性模型，就能解釋沒看過的國家約 85% 的平均壽命差異；收入組成、HIV/AIDS 與成人死亡率是最主要的因子。
- 依國家切分與同國中位數補值，是讓評估可信、模型更準的兩個關鍵。
- 限制：資料有錯誤與大量缺值；相關不等於因果；OLS 假設未全部滿足；未納入環境污染等其他因子。
- 未來改進：極端值縮尾處理、交互作用與非線性項、考慮國家內相關的混合效果模型，以及與隨機森林等非線性模型比較。

10. GPT 輔助內容（AI 工具：Claude）

依作業規定標示：以下列出本專案中由生成式 AI 工具協助完成的部分；與 AI 的完整對話紀錄另以 PDF 繳交。

使用的 AI 工具：

- **Claude（Claude Code）**：主要開發工具，負責程式撰寫、資料分析、網頁製作與報告文字草稿（含本報告書）。
- **NotebookLM**：研究網路上同主題的解法並產生摘要（見第 11 節）。

AI 協助的部分：資料集挑選建議、資料清理與補值策略、CRISP-DM 程式（main.py、feature_progression_analysis.py）、瀏覽器端統計引擎與特徵選擇演算法、網頁版面與圖表、報告文字草稿。

本人負責與確認的部分：

- **作業方向：**依作業要求提出需求，包括 CRISP-DM 流程、加分項目（資料集下拉選單、任意輸入資料集）、指定 Boston Housing 必須出現在選單中。
- **資料集決定：**參考作業說明中提供的資料集清單與 Claude 的建議，選定 WHO Life Expectancy，並自行從 Kaggle 下載資料；之後再從作業清單選定第二個 Kaggle 資料集 Predict the Flood，自行接受競賽規則並下載。
- **專案與部署：**建立 GitHub repository，將 HW2 與 HW1 分開管理；在 Vercel 與 GitHub Pages 完成部署設定。
- **網站設計方向：**指定版面參考網站、選擇配色風格與黑貓元素，並多次檢視畫面、提出修改。
- **研究：**使用 NotebookLM 整理同主題文獻並產生摘要。
- **檢查與確認：**檢視分析結果、網站與報告內容，決定最終繳交版本。

驗證方式：網頁計算結果已與 Python（statsmodels、scikit-learn）逐項比對一致。

11. NotebookLM 摘要

使用 NotebookLM 研究網路上同主題（WHO Life Expectancy 迴歸分析）的解法後產生的摘要：

> **資料清理**多採用插值法填補缺漏值、縮尾處理（Winsorization）極端值，並校正數據末端零被截斷的錯誤。**核心預測因子**包含成人死亡率、受教育年數、HIV/AIDS 死亡率、資源收入組成（HDI）及疫苗覆蓋率。**使用模型**涵蓋多元線性迴歸、Ridge 與 Lasso 正則化模型及隨機森林；其中隨機森林與二次多項式迴歸**評估結果**最佳（R^2 達 0.92 以上）。**常見限制**則為原始資料缺漏率高、變數間存在高度共線性，以及未納入環境污染等潛在因子。

NotebookLM 使用的來源

1. Kaggle：Life Expectancy (WHO) 資料集頁面：https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who
2. Kaggle：WHO Life Expectancy – Multi Linear Regression：https://www.kaggle.com/code/captainozlem/who-life-expectancy-multi-linear-regression
3. Kaggle：(Detailed) REGRESSION PROJECT on Life Expectancy：https://www.kaggle.com/code/ecedolen/detailed-regression-project-on-life-expectancy
4. Enjoy Algorithms：Life Expectancy Prediction Using Machine Learning：https://www.enjoyalgorithms.com/blog/life-expectancy-prediction-using-linear-regression/
5. NYC Data Science Academy：Modeling Life Expectancy：https://nycdatascience.com/blog/student-works/life-expectancy-by-country/
6. CAUSE USCLAP：Analyzing Significant Predictors of Life Expectancy across Countries：https://www.causeweb.org/usproc/sites/default/files/usclap/2022-1/analyzing-significant-predictors-of-life-expectancy-across-countries.pdf
7. arXiv 2510.00542：Interpretable Machine Learning for Life Expectancy Prediction: A Comparative Study of Linear Regression, Decision Tree, and Random Forest：https://arxiv.org/abs/2510.00542
8. iJOE（2022）：Life Expectancy Prediction through Analysis of Immunization and HDI Factors using Machine Learning Regression Algorithms：https://online-journals.org/index.php/i-joe/article/view/33315
9. GitHub：frinkleko/Life-expectancy（Data mining group project）：https://github.com/frinkleko/life-expectancy

與本專案的比較（本專案自行分析，非 NotebookLM 內容）

- **預測因子一致：**文獻指出的成人死亡率、HIV/AIDS、收入組成指數與疫苗覆蓋率，正是本專案選出的 4 個特徵。
- **R^2 較低的原因：**文獻的 R^2 0.92 以上多半來自隨機切分；本專案依國家切分，測試國家完全沒出現在訓練中，R^2 0.850 是更接近實際應用的估計。
- **模型選擇：**隨機森林與多項式迴歸分數較高但不再是線性模型、較難解釋；本專案依作業要求使用線性迴歸，並以 Ridge / Lasso 確認正則化沒有明顯改善。
- **資料清理：**文獻用插值與縮尾處理；本專案用同國中位數補值、刪除錯誤過多的 BMI 欄、偏態變數取 log。縮尾處理與非線性項可列為後續改進方向。

12. 參考資料

1. KumarRajarshi. Life Expectancy (WHO). Kaggle. https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who
2. Kaggle. Predict the Flood（Playground Series Season 4, Episode 5）. https://www.kaggle.com/competitions/playground-series-s4e5
3. Chapman, P. et al. (2000). CRISP-DM 1.0: Step-by-step data mining guide.
4. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825–2830.
5. Seabold, S. & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python.

6. 版面參考：AIoT-DIC2 Multiple LR Explorer https://huanchen1107.github.io/AIoT-DIC2-MultipleLR/；StatsUnlock Multiple Linear Regression Calculator https://statsunlock.com/multiple-linear-regression-calculator/
7. 第 11 節所列 NotebookLM 來源。