WHO 平均壽命預測：CRISP-DM 多元線性迴歸

AIoT HW2 · Kaggle Life Expectancy (WHO) · 2026–10–27

目標：以 193 國、2000–2015 年的健康、經濟與社會指標，建立可解釋的多元線性迴歸模型，找出影響平均壽命的關鍵因子，並在「模型沒看過的國家」上評估預測能力與不確定性。

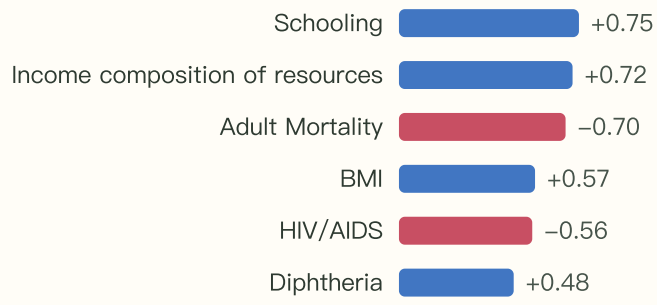
DATASET	RECORDS	FEATURES	TARGET	MODEL
Kaggle WHO	2,938 × 22	20 → 19	平均壽命（歲）	OLS · 4 個特徵

1 Business Understanding 商業理解

- 協助衛生政策分析：哪些指標與平均壽命最相關？對新國家能預測多準？
- 建模前訂定成功標準：測試集 $R^2 \geq 0.8$、RMSE ≤ 4.5 歲、分組 CV $R^2 \geq 0.75$

2 Data Understanding 資料理解

- 14 個欄位有缺值，44% 的列至少缺一個值
- BMI 有 48% 的值不合理（國家平均 > 50 或 < 10）
- 每國最多 16 年資料，同國各年份高度相似



3 Data Preparation 資料準備

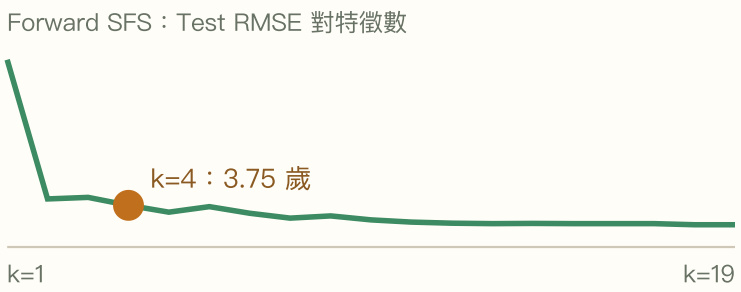
刪除 BMI 與無目標值的 10 列 → 不合理的 0 改為缺值 → 7 個偏態變數取 log → 依國家切分 146 / 37 國 → 同國中位數補值 3,243 格

4 Modeling 特徵選擇與建模

- Lasso、Forward SFS、RFE、ElasticNet × k = 1–19，以依國家分組的 5-fold CV 比較
- 1-SD 精簡原則選出 4 個特徵：

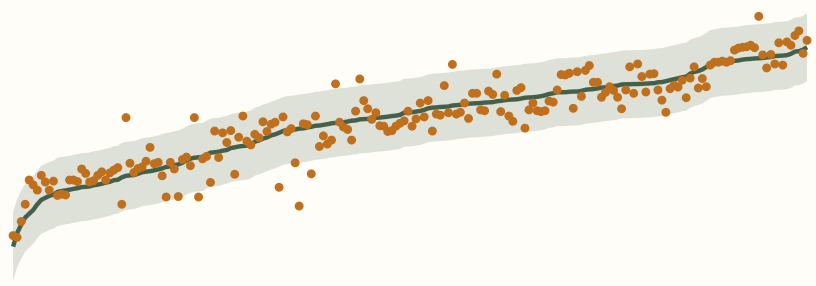
Income composition of resources · log HIV/AIDS · Adult Mortality · Diphtheria

- 與 Ridge、Lasso 比較；係數推論採依國家分群的穩健標準誤



5 Evaluation 評估（37 個沒看過的國家）

Test R^2	RMSE	95% PI 涵蓋
0.850	3.75	93.4%



測試集預測值（線）、95% 預測區間（帶）與實際值（點）

- 三項成功標準全部通過；部分 OLS 假設未通過，已誠實揭露並改用穩健推論

6 Deployment 部署

通過評估才部署 → 全部資料重新擬合 → joblib 儲存模型 → predict_life_expectancy() 回傳預測與區間 → 網站：報告 + 互動探索器

+ 互動探索器（加分）：6 個資料集、可任意輸入

- **第二個 Kaggle 資料集：Predict the Flood**（Playground Series S4E5）：20 個因子評分 → 洪水發生機率，抽樣 5,000 列
- 全部 20 個特徵的 OLS：測試集 R^2 0.842，95% 預測區間涵蓋 94.6%
- 另有 50 Startups、Advertising、Medical Insurance、Boston Housing；也可輸入 CSV 網址或上傳檔案

內建資料集	特徵 > 13 的 Kaggle 資料集	Flood 測試 R^2
6	2	0.842

R^2 0.850
只用 4 個特徵，在 37 個沒看過的國家解釋 85% 的壽命差異

依國家切分
測試國家完全不在訓練集，避免同一國家洩漏答案

資料清理是關鍵
刪除 48% 錯誤的 BMI；同國中位數補值讓 R^2 0.813 → 0.850

附預測區間
單一預測約 ±7 歲，93.4% 實際值落在 95% 區間內

報告：https://aiot-hw2-multiple-linear-regression.vercel.app/ · 程式：https://github.com/taemiyu/AIOT-HW2-Multiple_Linear_regression